Activitat. Entrenem i millorem un model d'IA

1. Descripció

En aquesta activitat, l'alumnat descobreix com les dades influeixen en l'entrenament i el funcionament d'un model d'IA. Per fer-ho, realitza tres reptes pràctics: un CAPTCHA d'etiquetatge, l'entrenament d'un minimodel amb Teachable Machine i la millora del model afegint més dades per comparar-ne els resultats.

2. Objectius específics

- Comprendre què és la IA generativa.
- Identificar raons per les quals pot generar respostes plausibles però incorrectes.
- Entrenar un model bàsic de classificació d'imatges amb Teachable Machine a partir d'un conjunt limitat de dades.
- Millorar el rendiment del model incrementant la quantitat i varietat de dades.

3. Continguts específics

- Inteligencia artificial generativa
    - Definició
    - Contingut sintètic
- Entrenament de la IA
    - Recull d'exemples
    - Aprenentatge de patrons
    - Ajust per reduir errors
    - Predicció
- *Human in the loop*
    - Intervenció humana en l'etiquetatge i la millora del model
    - CAPTCHA
- Limitacions i riscos
    - Biaixos i estereotips
    - Informació falsa però versemblant
    - Necessitat de verificació i criteri
- *Prompts*
    - Instruccions clares i precises

4. Temporització

Aquesta activitat té una durada aproximada d'entre 5 i 6 hores.

5. Agrupament

Es recomana treballar amb tot el grup classe la presentació i en grups reduïts de dues persones els reptes.

6. Recursos i materials

- Ordinador per al docent
- Ordinadors per a l'alumnat
- Projector

7. Activitat

Iniciem l'activitat amb la **"Presentació 1: La IA generativa"**, que ens serveix de fil conductor per als reptes de la sessió: **entendre com s'entrena una IA** i comprovar, a través de casos pràctics, que la **qualitat de les dades** i la **coherència dels criteris d'etiquetatge** determinen fins a quin punt un model és fiable.

Al llarg dels reptes, l'alumnat observa que si no compartim criteris o treballem amb dades pobres, el model s'equivoca més, i que els resultats milloren quan augmentem la quantitat i la varietat d'exemples i els validem amb proves comparables abans i després.

A partir de la presentació, definim la **IA generativa** com un tipus d'intel·ligència artificial capaç de **crear contingut nou** (text, imatges, àudio...) a partir del que ha après prèviament. És a dir, genera la resposta que considera més probable segons els patrons apresos; per això pot sonar molt segura i, tot i així, equivocar-se.

Aquest contingut és el que anomenem **contingut sintètic**: **no és una còpia exacta** d'un text o d'una imatge existent, sinó una producció nova que el model

construeix combinant el que ha après durant l'entrenament amb **grans quantitats de dades**.

A continuació, expliquem de manera senzilla **com s'entrena una IA** i presentem el procés en quatre passos:

1. En primer lloc, **recull exemples (dades)**: el model s'entrena amb una gran quantitat d'exemples que li serveixen de base.
2. Després, **aprèn patrons**: identifica regularitats que es repeteixen en aquests exemples (formes, textures, parts del cos...).
3. A continuació, **ajusta per encertar**: fa prediccions, les compara amb el resultat esperat i es corregeix repetidament per reduir errors.
4. Finalment, quan li arriba un cas nou, **dona la resposta més probable** segons els patrons que ha après.

En aquest punt, remarquem que aquests sistemes **no milloren sols**: hi ha persones que hi intervenen. Aquest procés s'anomena ***human in the loop*** i vol dir que humans **revisen exemples**, **corregeixen respostes** i **indiquen quines opcions són més adequades** perquè el model s'afini i cometi menys errors.

Sovint, mentre fem servir aquestes eines, es **recullen dades** (respostes, seleccions o exemples) que poden servir per **millorar** els sistemes. Un exemple clar són els **CAPTCHA**: quan marquem semàfors o passos de vianants, no només demostrem que no som un robot; també podem estar aportant **etiquetes** que ajuden a refinar el **reconeixement d'imatges**.

Finalment, posem el focus en els **límits i riscos** de la IA generativa: pot **reproduir biaixos i estereotips**, pot generar **informació falsa però versemblant**, es pot utilitzar per **manipular textos o imatges** (incloent *deepfakes*) i és fàcil **humanitzar-la** quan, en realitat, **no té intencions ni consciència**.

Per minimitzar aquests riscos, establim dues pautes bàsiques: **verificar quan hi ha dubte** (contrastant fonts i evidències) i **formular *prompts* amb criteris clars**. Per això, insistim que un bon *prompt* ha d'indicar com a mínim: **què volem**, **per a qui** (públic), **en quin format**, **amb quina extensió** i **amb quines condicions**.

Activitat. Entrenem i millorem un model d'IA

A continuació, organitzem l'aula en **grups reduïts de dues persones** i plantegem l'activitat pràctica com un **recorregut en tres reptes**. Treballem al llarg de tota la sessió amb el **"Document de treball: Entrenem un model d'IA per reconèixer objectes"**, que ens serveix per registrar decisions, proves i conclusions en cada fase.

Repte 1. Etiquetem dades com ho faria una IA

Iniciem el primer repte per comprendre el **primer pas de qualsevol entrenament d'IA**: **recollir dades i etiquetar-les de manera consistent**.

Projectem una sèrie d'imatges i les plantegem com un **CAPTCHA de classe**. Incloem tant **casos clars** com **casos frontera** (triangles inacabats, formes tallades, línies que poden ser ombres o ratlles, arcs que no formen un cercle complet) amb la intenció de generar discrepàncies i evidenciar la necessitat de criteris compartits.

Per a cada imatge, han de respondre **sí o no** a tres preguntes fixes i registrar la resposta al document de treball:

- Hi ha **ratlles**?
- Hi ha **triangles**?
- Hi ha **una rodona gran**?

En acabar, tornem a projectar totes les imatges i identifiquem aquelles on hi ha hagut **més desacord** entre grups. A partir d'aquí, obrim un breu debat:

- Què compta i què no compta com a ratlla?
- Què entenem per rodona gran? Quina mida mínima ha de tenir per ser considerada gran?

Fem explícit que, davant les **mateixes imatges**, les respostes no sempre coincideixen perquè cada grup ha aplicat **criteris diferents**.

A partir d'aquí, enllacem amb una idea clau sobre la IA: quan entrenem un model, **les etiquetes es converteixen en la referència** que el sistema utilitza per aprendre. Si aquesta referència **no és coherent** i varia segons qui etiqueta o com s'interpreta cada cas, el conjunt de dades esdevé inconsistent i el model rep **informació contradictòria**. Com a conseqüència, pot acabar aprenent patrons

poc rellevants o bé aprendre amb menys precisió; en tots dos casos, augmenta la probabilitat d'error quan s'enfronta a situacions noves.

Repte 2. Entrenem un model d'IA amb Teachable Machine

Plantegem el segon repte per comprovar que, **si entre humans no sempre coincidim quan etiquetem**, un model pot aprendre encara pitjor quan treballa amb **dades pobres o repetitives**. Expliquem que entrenarem un **model d'IA senzill de classificació d'imatges** amb **Teachable Machine** perquè reconegui objectes de l'aula.

Per fer visible l'impacte de les dades, començarem intencionadament amb un ***dataset* limitat** (poques imatges i molt semblants) per poder **observar errors** i identificar-ne possibles causes. A la dinàmica següent, millorarem el resultat **sense canviar l'eina**: només millorarem les **dades** (més quantitat i més varietat) i compararem si el model respon millor quan el *dataset* és més complet.

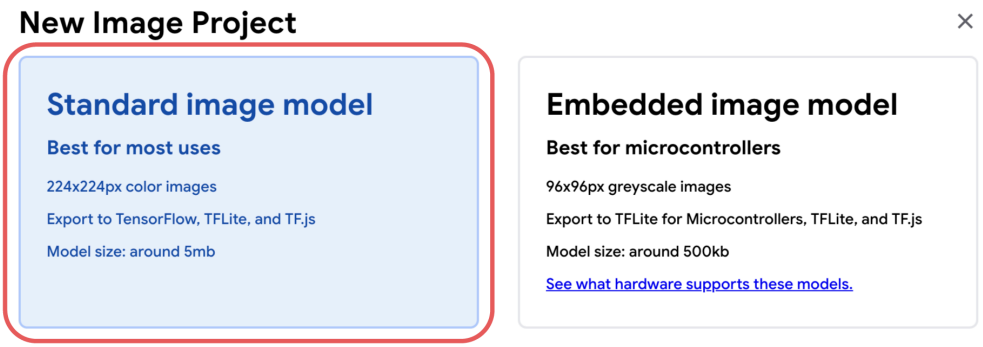
TEACHABLE MACHINE

És una eina web que permet entrenar, de manera guiada, un **model d'IA de classificació d'imatges**. El procés és senzill: es defineixen **classes** (categories), es recullen **mostres** per a cada classe (amb captures de càmera o imatges) i l'eina entrena el model perquè aprengui a **distingir-les**.

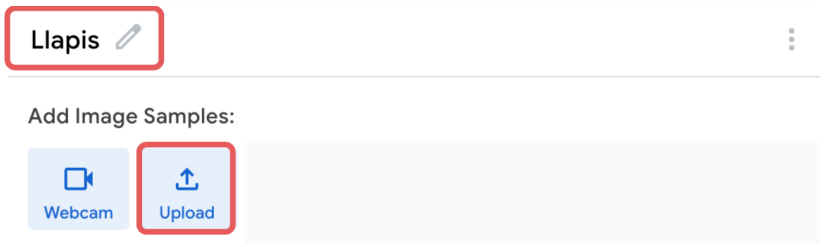
Un cop entrenat, activem la **predicció en temps real** perquè el sistema indiqui a quina classe creu que pertany l'objecte que veu, habitualment amb un **nivell de confiança**.

Seguim aquests passos:

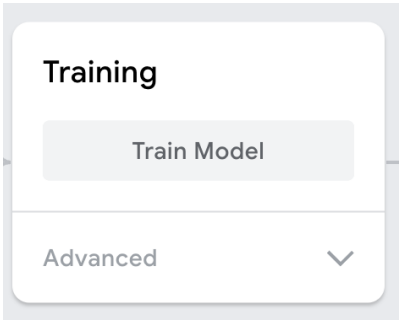
1. Obrim Teachable Machine amb l'enllaç corresponent: https://teachablemachine.withgoogle.com/train.
2. Creem un projecte d'**Image Project** i seleccionem **Standard image model**.



3. Creem **tres categories**: bolígraf, llapis i retolador. Amb l'opció ***Upload***, pugem només una imatge per categoria, triant-ne una de les tres disponibles a la **carpeta "Imatges repte 2"**.



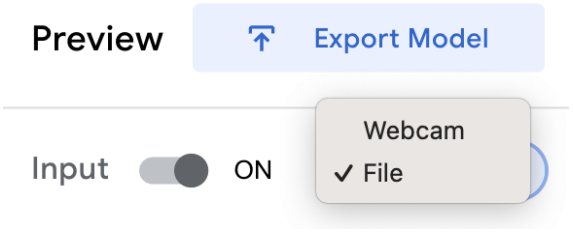
4. **Entrenem el model** fent clic a ***Train Model*** perquè **Teachable Machine** processi les imatges de cada categoria i generi un model capaç de **distingir-les**.



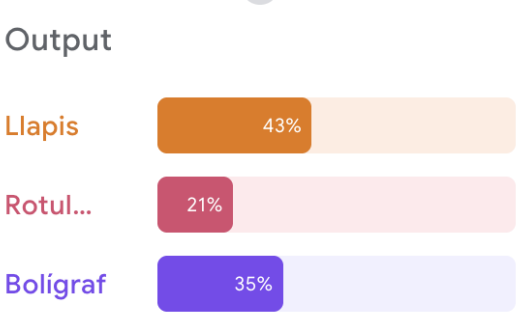
5. **Posem a prova el model.** Cada grup crea 3 noves imatges d'aquests objectes a l'aula per comprovar com es comporta el model amb diferents **variables:**
   - **Variable 1. Canvi de fons**: mostren l'objecte entrenat (per exemple, el retolador) davant d'un fons diferent (carpeta, paret, terra...). Observen si el model el confon o si canvia de classe.

- **Variable 2. Canvi d'angle o distància**: sense canviar l'objecte, el giren (vertical/horitzontal o lleugerament inclinat) o el col·loquen més a prop o més lluny de la càmera. Tornen a observar la predicció i registren si apareixen errors.
- **Variable 3. Objecte parcialment tapat**: tapen parcialment l'objecte (sense ocultar-lo del tot) i comproven si baixa la confiança o si el model s'equivoca.

Aquesta verificació es pot fer de dues maneres, segons el dispositiu disponible: mostrant l'objecte directament davant la càmera, si es treballa amb tauleta, o bé pujant una imatge amb l'opció *Upload*, si es treballa amb ordinador. Abans de fer la prova, cal assegurar-se que l'opció *Input* estigui en **ON** i, tot seguit, seleccionar ***File*** o ***Webcam.***



Un cop hem mostrat o pujat la imatge, el model fa una predicció i indica, amb un percentatge, quin objecte creu que és:



Al document de treball, l'alumnat registra els errors. Per a cada error, anoten **què han canviat** (fons, angle/distància o posició), **què ha predit el model** i **quina era la resposta correcta**. Tot seguit, hi afegeixen una **hipòtesi breu de causa**.

Repte 3. Perfeccionem el model millorant les dades

En aquest repte, l'alumnat amplia el ***dataset*** amb un conjunt d'imatges més nombrós i més **variat**. Això permet que el model aprengui més patrons i millori la seva capacitat de reconèixer els objectes.

Abans de fer noves captures, compartim una ***checklist* breu** de qualitat de dades per orientar la recollida. Cal augmentar el nombre d'exemples de cada categoria i assegurar una major varietat d'imatges de **retoladors, bolígrafs i llapis**.

Fins ara, el model només disposava d'**una imatge de referència per categoria**. Ara, l'objectiu és ampliar aquest conjunt fins a tenir **5 imatges per categoria**, és a dir, **15 captures en total**.

Quan el nou *dataset* està complet, demanem que **reentrenin el model** prement ***Train Model***. Per comprovar si realment hi ha millora, insistim que han de repetir **exactament les mateixes proves** del repte anterior. Activem la predicció en temps real i tornem a provar el model amb tres situacions: **canvi de fons**, **canvi d'angle o distància** i **ombra o objecte parcialment tapat**.

L'objectiu és comparar els resultats **abans i després** amb criteri. Al document de treball, l'alumnat registra el resultat de les proves i completa tres aspectes: què ha millorat, per què creu que ha millorat i quin cas encara falla i com es podria continuar millorant.

Tanquem el repte amb una **posada en comú breu**. Cada grup comparteix un error inicial, la millora aplicada i una conclusió transferible: quan **millorem la qualitat i la varietat de les dades**, el model esdevé **més robust** i respon millor davant canvis de context. Ho connectem amb la idea general de la sessió: els resultats d'una IA depenen en gran mesura del que li proporcionem, ja sigui en forma de **dades** en models entrenats o d'**instruccions clares** en el cas de la IA generativa.